

강화학습의 기초

식단 추천 에이전트

강화학습 기반 개인화 영양소 최적화

데이터사이언스 김선우(A74004)

| Github https://github.com/swoo515/diet_rl.git



목차

Contents

01	프로젝트 개요 및 배경	3
	문제 정의 · RL 적용 이유	
02	MDP 설계	4
	State · Action · Reward · 최적화 목표	
03	강화학습 알고리즘	5
	Q-learning · DQN · REINFORCE	
04	구현	6
	환경 설계 · 에이전트 구현 · 학습 흐름	
05	비교 실험 및 알고리즘 선정	7
	3가지 비교 실험 + DQN 선정 근거	
06	최종 모델 학습 및 결과	11
	DQN 최적 하이퍼파라미터 · 학습 곡선	
07	결론	13
	핵심 발견 · 한계점 · 향후 방향	

프로젝트 개요 및 배경

1

프로젝트 목적

식단 선택을 순차적 의사결정 문제로 모델링하여, 매 끼니마다 영양 상태에 따라 동적으로 적응하는 RL 기반 에이전트를 설계하고 최적 알고리즘을 탐색한다.

2

최적화 목표

일주일(21스텝) 동안의 누적 보상 최대화
= 영양소 목표 달성을 최대화 + 식사 다양성 확보 + 끼니별 균형 유지

3

RL이 적합한 이유


- 순차적 의사결정: 아침→점심→저녁, 21스텝
- 정답 라벨 없음: 최적 식단이 정해져 있지 않음
- 장기 보상 최적화: 오늘 편식이 주간 영양 불균형으로 이어짐

프로젝트 목표

- 식단 추천 환경 MDP 직접 설계
- 3가지 RL 알고리즘 직접 구현
- 알고리즘 간 성능 비교
- 하이퍼파라미터 영향 분석
- 최적 모델 선정 및 식단 추천

MDP 설계

* 1 에피소드 = 일주일 (7일 x 3끼 = 총 21 스텝)



요소	정의	상세 내용
State	현재 상황 벡터 (6차원)	남은 영양소 비율 4개 + 전체 진행률 + 현재 요일 (월=0, 일=1)
Action	음식 1개 선택	음식 DB 500개 중 하나 선택 (Action Index 0~499)
Reward	다목적 보상 함수	영양소 달성률 (달성 비율만큼 +, 최대 +4/스텝) / 초과 섭취 (-2×) / 당일 반복 (-2.0) / 끼니별 칼로리 분배 (-2.0) / 단백질 부족 (-1.5) / 탄수화물 부족 (-1.5) / 일별 균형 (-1.5)
Episode	일주일 단위	월 ~ 일 7일 x 아침/점심/저녁 = 총 21 스텝 후 종료

강화학습 알고리즘

공통 입력 (State) 남은 영양소 비율 + 전체 진행률 + 요일 (6차원) → 공통 출력 (Action) 500개 음식 중 1개 선택

01

Q-learning

Q-table 기반 가치 함수 학습

State 이산화

6차원 → 각 5구간 분할 → Q-table (312.5만 칸)

탐험 전략

epsilon-greedy: 1.0 → 0.01 (decay 0.995)

업데이트

벨만 방정식, $lr=0.001$, $\gamma=0.95$

한계

6차원 Q-table로 메모리 부담 증가

02

DQN

신경망으로 Q값 근사

신경망 구조

6 → 128 → 128 → 500 (ReLU 81,908 파라미터)

Replay Memory

10,000개 경험 저장, 64개 무작위 샘플링

Target Network

10 에피소드마다 Main Net → Target Net 동기화

최종 선정

비교 실험 결과 DQN을 최종 알고리즘으로 선정

03

REINFORCE

정책 확률 분포를 직접 학습

Policy Network

6 → 128 → 128 → 500 (Softmax 출력)

행동 선택

확률 분포에서 샘플링 (epsilon 없음)

학습 시점

에피소드 종료 후 $\text{Return}(G_t)$ 으로 일괄 업데이트

특징

비교 실험에서 가장 낮은 평균 reward 기록

구현

개발 환경

언어 Python 3.14

딥러닝 프레임워크 PyTorch 2.12

데이터 Kaggle Food Nutrition Dataset

(출처: kaggle.com/datasets/utsavdey1410)

전처리 컬럼명 표준화, 필수 영양소 컬럼 추출, 결측치 제거

음식 수 (Action Space) 2,395개 중 500개 랜덤 샘플링

에피소드 수 1,000

반복 횟수 5 runs (신뢰도 확보)

파일 구조

`environment.py`

DietEnv — State/Action/Reward 정의

`agents/q_learning.py`

Q-table 기반 에이전트

`agents/dqn.py`

신경망 + Replay + Target Net

`agents/reinforce.py`

PolicyNetwork + Return 계산

`train.py`

단일 알고리즘 학습 실행

`experiment.py`

비교 실험 자동 실행 + 그래프

`evaluate.py`

최종 모델 평가 + 식단 추천 출력

실험 설계

실험 1

알고리즘 비교

비교: Q-learning vs DQN vs REINFORCE 고정: $lr=0.001 \cdot \gamma=0.95$

실험 2

학습률(lr) 비교

비교: $lr = 0.0001$ vs 0.001 vs 0.01 고정: DQN $\cdot \gamma=0.95$

실험 3

할인율(γ) 비교

비교: $\gamma = 0.9$ vs 0.95 vs 0.99 고정: DQN $\cdot lr=0.001$


Evaluation Metric

- 각 설정별 seed 0~4로 5회 반복 실행
- 마지막 50 episode의 평균 reward를 최종 성능 지표로 사용
- 5회 결과의 평균, 표준편차, 95% 신뢰구간으로 성능 비교

공통 설정: 음식 500개 · 에피소드 1,000 · Seed 0~4 5회 반복 실행 · Reward 함수: 영양소 달성 + 5가지 페널티 적용

실험 1

알고리즘 비교 | Q-learning vs DQN vs REINFORCE



1위 DQN

평균 25.35 ± 7.35
95% CI [16.22, 34.47]

2위 Q-learning

평균 4.83 ± 4.11
95% CI [-0.28, 9.94]


3위 REINFORCE

평균 -2.12 ± 16.86
95% CI [-23.05, 18.81]

DQN이 가장 높은 평균 reward 달성

실험 2

학습률(lr) 비교 | DQN 기준



$lr = 0.001$

평균 25.35 ± 7.35
95% CI $[16.22, 34.47]$

$lr = 0.0001$

평균 11.72 ± 13.04
95% CI $[-4.47, 27.91]$


$lr = 0.01$

평균 6.82 ± 11.67
95% CI $[-7.67, 21.32]$

**$lr = 0.001$ 이 성능과
안정성 모두 최적**

실험 3

할인율(γ) 비교 | DQN 기준



$\gamma = 0.9$

평균 28.21 ± 5.35
95% CI [21.57, 34.85]

$\gamma = 0.95$

평균 25.35 ± 7.35
95% CI [16.22, 34.47]

$\gamma = 0.99$

평균 22.49 ± 7.59
95% CI [13.07, 31.91]

$\gamma = 0.9$ 가 가장 높은 평균 reward &
가장 낮은 표준편차 달성

최종 모델 학습 및 결과

비교 실험 결과 DQN 선정 → 최적 하이퍼파라미터 $lr=0.001 \cdot \gamma=0.9$ → episodes 1,000 · max_foods 500 · Seed 42로 최종 학습

학습 곡선 (에피소드별 평균 reward)

Episode	평균 Reward	Epsilon
50	-50.295	0.778
200	-22.694	0.367
400	4.600	0.135
600	18.561	0.049
800	17.981	0.018
950	22.438	0.010
1000	24.270	0.010

최종 모델 성능

24.270

최종 평균 reward (episode 1,000)

알고리즘

DQN

학습률 (lr)

0.001

할인율 (γ)


0.9

학습 전환 (음수 → 양수)

~400 ep

최종 모델 평가

DQN vs Random Baseline



17 추천 주간 식단

월	아몬드 페이스트 / 생 돼지고기 / 동부콩
화	동부콩 / 아몬드 페이스트 / 딜 허브
수	무지방 감자칩 / 치즈 크루아상 / 아몬드 페이스트
목	무지방 감자칩 / 딜 허브 / 딜 허브
금	무지방 감자칩 / 무지방 감자칩 / 긴줄콩
토	딜 허브 / KFC 크리스피 치킨 브레스트 / KFC 크리스피 치킨 브레스트
일	딜 허브 / 긴줄콩 / 보리가루

DQN 평균 reward ~27 | Random 평균 ~-57 | DQN 개선을 무작위 선택 대비 우수 | Random은 페널티로 음수 reward

결론

▶ 알고리즘

- DQN > Q-learning > REINFORCE
- 세 알고리즘 중 DQN이 가장 높은 평균 reward 달성

▶ 학습률

- $lr=0.001$ 성능, 안정성 모두 최적 (std 7.35로 안정적)
- $lr=0.01$ 평균 6.82로 가장 낮은 성능

▶ 할인율

- $\gamma=0.9$ 평균 28.21로 가장 높은 성능과 낮은 분산(5.35) 달성

▶ 한계 및 향후

- 추천 식단에서 특정 음식 반복 및 현실성 부족 관찰
- 영양 균형 · 다양성 · 선호도를 반영한 Reward 함수 고도화 필요

핵심 결과 요약

- DQN 최종 평균 reward 24.270
- 최적 설정: $lr=0.001$, $\gamma=0.9$
- 학습된 DQN이 무작위 선택 대비 일관되게 높은 성능 달성

배운 점

- MDP 직접 설계를 통한 문제 모델링 경험
- 3가지 RL 알고리즘 직접 구현 및 성능 비교
- Reward 설계가 학습 방향과 성능에 미치는 영향 확인
- 반복 실험을 통한 신뢰도 높은 결과 도출 방법